

Dakar Institute of Technology



RepSEN/Ensup-priv/AP/376-2021

Domaine : Sciences et Technologies

Département : Informatique

Spécialité : Intelligence Artificielle

Projet Informatique

Présenté par :

➤ **Rosalex AHAN**

➤ **Willane Jaures SABOUBANGA**

SUJET :

Modèle IA permettant de faire des prévisions météo sur plus d'une
semaine : cas du Sénégal

Année Académique : 2023-2024

DÉDICACE

À nos parents,

Pour leur amour inconditionnel, leur soutien constant, et leurs sacrifices innombrables, sans lesquels ce projet n'aurait jamais vu le jour. Nous vous dédions ce travail en signe de notre reconnaissance éternelle.

REMERCIEMENTS

Nous souhaitons remercier du fond du cœur toutes les personnes qui ont contribué à la réalisation de ce projet.

Nos remerciements vont en premier lieu à nos parents, pour leur amour, leur soutien sans faille, et pour avoir toujours cru en nous. Vous avez été nos plus grandes sources de motivation.

Nous tenons également à remercier nos enseignants, pour leurs expertises, patience et précieux conseils. Votre encadrement a été essentiel dans la réalisation de ce projet.

Un grand merci à nos amis, pour leur soutien moral, leurs encouragements, et pour les moments de détente partagés qui nous ont permis de garder le cap.

Enfin, nous remercions toutes les personnes qui ont, de près ou de loin, apporté leur aide et leur soutien dans ce projet. Vous avez joué un rôle clé dans la réussite de ce travail.

LISTE DES FIGURES

Figure 1 : Visualisation du Shape et des 10 premières lignes de notre dataset

Figure 2 : Information about the dataset

Figure 3 : Description du dataset

Figure 4 : Evaluations des performances selon les stations (1)

Figure 5 : Evaluations des performances selon les stations (2)

Figure 6 : Visualisation des resultats

RÉSUMÉ

Ce projet de fin d'année présente le développement et l'évaluation d'un modèle d'intelligence artificielle (IA) conçu pour effectuer des prévisions météorologiques précises. L'objectif principal est d'explorer l'utilisation de l'apprentissage automatique pour améliorer la précision des prévisions à court et moyen terme, en se basant sur des données météorologiques historiques et en temps réel.

Pour ce faire, une approche de réseau de neurones récurrents (RNN), plus spécifiquement un modèle LSTM (Long Short-Term Memory), a été utilisée pour capturer les dépendances temporelles complexes présentes dans les données climatiques. Le modèle a été entraîné sur un vaste ensemble de données provenant de diverses sources, y compris les stations météorologiques et les satellites, et a été testé sur des données de validation pour évaluer ses performances.

Les résultats obtenus montrent que le modèle IA est capable de prédire avec une grande précision des variables météorologiques clés telles que la température, les précipitations et la pression atmosphérique, surpassant les modèles traditionnels dans plusieurs scénarios. Le modèle s'avère particulièrement efficace pour les prévisions à court terme, où il peut anticiper les changements rapides dans les conditions météorologiques.

En conclusion, ce projet démontre le potentiel des techniques d'IA pour améliorer les prévisions météorologiques, offrant ainsi une alternative prometteuse aux méthodes conventionnelles. Les implications de ces résultats sont significatives pour les secteurs dépendant des prévisions météo, tels que l'agriculture, l'aviation et la gestion des catastrophes naturelles. Le projet propose également des pistes d'amélioration pour les futures recherches, notamment l'intégration de données supplémentaires et l'utilisation de modèles plus complexes pour les prévisions à long terme.

Projet Informatique	1
1 INTRODUCTION	8
2 CHAPITRE I : Etat de l’art	9
2.1 Etat de l’art sur le domaine de l’application	9
2.2 Etat de l’art sur les travaux de recherche pertinentes liées au sujet	9
2.3 Identification des zones de recherches manquantes liées au sujet	10
3 CHAPITRE II: Analyse de besoins et Méthodologie	12
3.1 Analyse et Spécification des Besoins.....	12
3.2 Sources de Données	12
3.3 Processus de Collecte	13
3.4 Pré-processing des Données.....	13
4 II. Méthodologie	13
4.1 Choix des Algorithmes et Modèles	13
4.2 Justification des Choix	14
4.3 Évaluation des Performances	14
4.4 Métriques Utilisées.....	14
4.5 Protocole d'Évaluation	14
5 Chapitre III : Implémentation	15
5.1 Analyse exploratoire du des données	15
5.2 Résultats des modèles.....	17
5.3 II. Outils de développement et de déploiement.....	20
5.4 Environnement de Développement	20
5.5 Technologies de Développement	21
5.6 Architecture de la Solution.....	21
5.7 Architecture et Services du Déploiement.....	21
6 CONCLUSION GENERALE	22
6.1 Bilans de l'Étude.....	22

6.2	Perspectives.....	22
-----	-------------------	----

1 INTRODUCTION

Les prévisions météorologiques jouent un rôle crucial dans de nombreux secteurs, tels que l'agriculture, l'aviation, la gestion des catastrophes naturelles, et bien d'autres. Prédire avec précision les conditions météorologiques à court et moyen terme est essentiel pour la prise de décisions stratégiques, la planification des activités, et la protection des vies humaines. Cependant, malgré les avancées technologiques, les méthodes traditionnelles de prévision restent confrontées à des limitations, notamment en ce qui concerne la complexité et la volatilité des phénomènes météorologiques.

Avec l'émergence de l'intelligence artificielle (IA) et de l'apprentissage automatique, de nouvelles opportunités s'offrent pour améliorer la précision des prévisions météorologiques. Les modèles de réseaux neuronaux, en particulier les réseaux à mémoire longue et courte durée (LSTM), sont capables de capturer des patterns temporels complexes dans les données, offrant ainsi une alternative prometteuse aux approches conventionnelles.

Ce projet se propose d'explorer l'application des modèles LSTM pour la prévision des conditions météorologiques. En exploitant des ensembles de données massifs issus de diverses sources, telles que les stations météorologiques et les satellites, l'objectif est de développer un modèle capable de prédire avec précision des variables clés comme la température, les précipitations, et la pression atmosphérique.

L'introduction d'une telle approche innovante dans le domaine de la météorologie pourrait non seulement améliorer la qualité des prévisions, mais aussi avoir des répercussions significatives sur les secteurs dépendant de la météo. Ce projet vise donc à contribuer à cette avancée en fournissant un modèle IA performant, en évaluant sa précision par rapport aux méthodes traditionnelles, et en explorant ses applications potentielles dans des contextes réels.

2 CHAPITRE I : Etat de l'art

2.1 Etat de l'art sur le domaine de l'application

Les prévisions météorologiques sont essentielles pour de nombreux domaines tels que l'agriculture, la gestion des ressources en eau, l'aviation, et la gestion des catastrophes naturelles. Traditionnellement, les prévisions sont réalisées à l'aide de modèles numériques de prévision météorologique (NWP), qui se basent sur des équations différentielles pour simuler le comportement de l'atmosphère. Ces modèles, bien qu'efficaces à grande échelle, présentent des limites en matière de précision à court terme et à échelle locale, notamment en raison de la complexité des phénomènes météorologiques et des approximations nécessaires pour résoudre les équations en temps réel.

L'arrivée de l'intelligence artificielle (IA) a ouvert de nouvelles perspectives dans ce domaine. Les modèles d'apprentissage automatique, et en particulier les réseaux de neurones profonds, permettent de traiter de grandes quantités de données météorologiques pour identifier des patterns complexes et réaliser des prévisions plus précises. Les domaines d'application incluent non seulement les prévisions météo classiques mais aussi la prévision de phénomènes spécifiques comme les tempêtes, les vagues de chaleur, ou encore la qualité de l'air.

2.2 Etat de l'art sur les travaux de recherche pertinentes liées au sujet

Plusieurs travaux de recherche récents se sont concentrés sur l'utilisation de l'IA pour améliorer la précision des prévisions météorologiques. Les réseaux de neurones récurrents (RNN), et plus spécifiquement les modèles LSTM (Long Short-Term Memory), se sont révélés particulièrement efficaces pour capturer les dépendances temporelles présentes dans les séries chronologiques météorologiques.

Par exemple une étude de Shi et al (2005) a démontré que les modèles LSTM pouvaient surpasser les modèles traditionnels pour les prévisions à court terme et de rapidité.

En outre, des études ont également exploré l'utilisation de modèles IA pour des applications spécifiques, comme la prévision de la qualité de l'air (par exemple, une étude réalisée par Li et al (2007) a utilisé un modèle de réseaux de neurones artificiels (ANN) pour prédire les

concentrations de PM.25 a Pékin. Les auteurs ont comparé les performances de ce modèle avec celles d'un modèle statistique traditionnel (régression linéaire) et ont constaté que l'ANN surpassait largement les méthodes traditionnelles en termes de prédictions

2.3 Identification des zones de recherches manquantes liées au sujet

Bien que les avancées de l'IA aient permis des progrès significatifs dans les prévisions météorologiques, plusieurs zones de recherche demeurent insuffisamment explorées. Parmi celles-ci, on peut citer :

- **Prédictions à long terme** : La majorité des travaux actuels se concentre sur les prévisions à court terme (heures ou jours). Les prédictions à long terme (semaines ou mois) restent un défi, en grande partie à cause des incertitudes croissantes et des changements climatiques qui complexifient davantage les modèles.
- **Interprétabilité des modèles** : Les modèles de réseaux de neurones, notamment les LSTM, sont souvent perçus comme des "boîtes noires". Comprendre comment ces modèles prennent leurs décisions et identifier les facteurs les plus influents pour les prévisions reste un domaine de recherche crucial.
- **Intégration multi-sources de données** : Bien que de nombreuses études aient utilisé des données météorologiques classiques, l'intégration d'autres types de données, comme les images satellitaires en temps réel, les données issues de capteurs IoT, et les informations climatiques à long terme, reste encore peu explorée. Une telle intégration pourrait améliorer la précision et la fiabilité des prévisions.
- **Évaluation et validation** : Il existe un besoin pour des Framework standardisés permettant d'évaluer et de comparer les performances des modèles IA dans différents contextes météorologiques. Actuellement, les méthodes d'évaluation varient largement d'une étude à l'autre, rendant difficile la comparaison des résultats.

L'État de l'Art montre que l'application de l'intelligence artificielle, et en particulier des modèles LSTM, représente une avancée prometteuse pour les prévisions météorologiques, en particulier à court terme. Cependant, des zones de recherche importantes demeurent, notamment en ce qui concerne les prévisions à long terme, l'interprétabilité des modèles, l'intégration de données multi-sources, et l'évaluation standardisée des performances. Ce projet s'inscrit dans la poursuite de ces objectifs, en cherchant à combler certaines de ces lacunes tout en contribuant à l'amélioration générale des techniques de prévision météorologique basées sur l'IA.

3 CHAPITRE II : Analyse de besoins et Méthodologie

3.1 Analyse et Spécification des Besoins

L'objectif principal de ce projet est de concevoir un modèle d'IA capable de prédire les conditions météorologiques avec une grande précision. Les utilisateurs finaux incluent les météorologues, les agriculteurs, les compagnies aériennes, et les services de gestion des catastrophes, qui nécessitent des prévisions précises pour prendre des décisions critiques.

Les besoins fonctionnels du projet sont :

- La prédiction des conditions météorologiques à court terme (de quelques heures à quelques jours).
- La capacité à intégrer différentes sources de données météorologiques, telles que les relevés au sol, les images satellites, et les données des stations météorologiques.
- La génération de visualisations des prévisions, comme les cartes de précipitations et les graphiques de températures.

Les besoins non fonctionnels incluent :

- La rapidité des prévisions pour une utilisation en temps réel.
- La fiabilité et la précision du modèle, avec une marge d'erreur minimale.
- La compatibilité avec les systèmes existants utilisés par les agences météorologiques.

3.2 Sources de Données

Les données utilisées tout au long de ce projet provient exclusivement de l'ANACIM (Agence Nationale de l'Aviation et de la Météorologie). Ces données sont constituées de :

- **Données des stations météorologiques** : Température, humidité, vitesse du vent, pression atmosphérique, etc.
- **Modèles numériques de prévision météorologique (NWP)** : Fournissant des prédictions de grande échelle basées sur des équations physiques.

- **Données historiques** : Anciens relevés météorologiques, utilisés pour l'entraînement du modèle et la validation des prévisions.

3.3 Processus de Collecte

Les données météorologiques ont été collectées à partir de quelques stations météorologiques nationales. Ces données sont ensuite stockées dans une base de données centralisée et mises à jour régulièrement pour refléter les conditions météorologiques actuelles. Les données historiques sont également collectées pour l'entraînement initial du modèle.

3.4 Pré-processing des Données

Le pré-processing des données météorologiques inclut les étapes suivantes :

- **Nettoyage des données** : Élimination ou imputations des valeurs manquantes ou anormales (outliers) et interpolation des données manquantes.
- **Normalisation** : Mise à l'échelle des différentes variables (par exemple, normalisation de la température en °C, de la pression en hPa, etc.) pour garantir une contribution égale lors de l'entraînement des modèles.
- **Transformation** : Conversion des données brutes en formats exploitables par les modèles d'IA, par exemple, la création de séries temporelles à partir des données de capteurs.

4 II. Méthodologie

4.1 Choix des Algorithmes et Modèles

Pour ce projet, un seul algorithme a été sélectionné :

- **Artificial Neural Networks (ANN)** : Notamment les modèles LSTM (Long Short-Term Memory), qui sont particulièrement adaptés pour capturer les dépendances temporelles complexes dans les données météorologiques.

4.2 Justification des Choix

Le modèle LSTM a été choisi pour sa capacité à gérer les dépendances temporelles sur de longues périodes, ce qui est crucial pour les prévisions météorologiques.

4.3 Évaluation des Performances

L'évaluation des performances a été réalisée sur un ensemble de test indépendant, couvrant diverses conditions météorologiques (journées ensoleillées, pluvieuses, tempêtes, etc.). Les performances des modèles ont été comparées en termes de précision des prévisions (température, précipitations, etc.), et la marge d'erreur a été analysée pour chaque modèle.

4.4 Métriques Utilisées

Les métriques d'évaluation incluent :

- **Erreur Quadratique Moyenne (RMSE)** : Pour mesurer la différence moyenne entre les valeurs prédites et les valeurs réelles.
- **Erreur Absolue Moyenne (MAE)** : Pour évaluer l'erreur moyenne en valeur absolue, sans tenir compte de la direction de l'erreur.
- **Mean Square Error** : Le MSE est toujours positif, plus la valeur est proche de zéro le mieux

4.5 Protocole d'Évaluation

Un protocole d'évaluation a été mis en place pour estimer les performances des modèles de manière robuste et éviter le surapprentissage. Les données ont été divisées en plusieurs sous-ensembles, chacun utilisé pour l'entraînement et la validation, garantissant ainsi que les modèles sont testés sur des données non vues à chaque itération.

5 Chapitre III : Implémentation

5.1 Analyse exploratoire du des données

Le dataset avec lequel nous travaillons contient 2578 lignes te 10 colonnes. Les donnees sont classees selon les staions meteorologique de chaque region

(2578, 10)										
	Name_station	EVAP0	FF	INS	RR	TT, moy. des max	TT, moy. des min	UMAX	UMIN	Date
0	dakar-yoff	3.1	5.4	7.3	0.0	27.212	19.445	89.806	48.741	1992-01-01
1	dakar-yoff	2.3	5.9	8.0	3.7	23.841	18.437	95.862	71.103	1992-02-01
2	dakar-yoff	3.0	5.9	7.9	0.0	25.000	17.158	88.290	47.000	1992-03-01
3	dakar-yoff	2.3	7.5	8.2	0.0	23.333	18.020	92.266	67.433	1992-04-01
4	dakar-yoff	2.1	5.3	6.8	0.6	25.935	20.371	90.774	65.967	1992-05-01
5	dakar-yoff	2.5	3.4	7.5	0.0	27.966	23.080	90.933	68.800	1992-06-01
6	dakar-yoff	2.5	2.8	7.4	49.2	28.967	24.380	90.290	72.645	1992-07-01
7	dakar-yoff	2.3	2.9	7.3	86.6	29.967	24.893	87.548	67.838	1992-08-01
8	dakar-yoff	2.0	2.2	6.8	48.9	30.456	24.560	91.133	70.733	1992-09-01
9	dakar-yoff	3.1	3.6	8.7	0.8	29.990	23.845	90.419	61.806	1992-10-01

Figure 1 : Visualisation du Shape et des 10 premières lignes de notre dataset

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2578 entries, 0 to 2577
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Name_station          2578 non-null   object
1   EVAP0                 2578 non-null   float64
2   FF                   2578 non-null   float64
3   INS                   2578 non-null   float64
4   RR                   2578 non-null   float64
5   TT, moy. des max      2578 non-null   float64
6   TT, moy. des min      2578 non-null   float64
7   UMAX                  2578 non-null   float64
8   UMIN                  2578 non-null   float64
9   Date                  2578 non-null   datetime64[ns]
dtypes: datetime64[ns](1), float64(8), object(1)
memory usage: 201.5+ KB

```

Figure 2: Information about the dataset

	EVAP0	FF	INS	RR	TT, moy. des max	TT, moy. des min	UMAX	UMIN	Date
count	2578.000000	2578.000000	2578.000000	2578.000000	2578.000000	2578.000000	2578.000000	2578.000000	2578
mean	4.315091	3.103727	7.618580	60.575873	34.070533	21.758391	81.689696	42.460800	2006-04-20 18:48:18.991466240
min	0.400000	0.000000	0.000000	0.000000	12.000000	9.800000	9.140000	5.340000	1990-01-01 00:00:00
25%	2.700000	2.300000	7.200000	0.000000	32.000000	19.319500	75.000000	24.900750	1998-09-01 00:00:00
50%	3.600000	3.000000	7.800000	0.100000	33.900000	22.100000	88.871000	42.100000	2006-05-01 00:00:00
75%	5.300000	3.600000	8.300000	79.900000	36.400000	24.069250	93.091000	61.000000	2014-01-01 00:00:00
max	13.000000	38.100000	56.000000	836.700000	186.700000	172.100000	121.500000	95.000000	2022-12-01 00:00:00
std	2.447594	1.877412	2.044599	110.841029	4.815168	4.192876	17.060610	19.349456	NaN

Figure 3 : Description du dataset

5.2 Résultats des modèles

```
Performance du modèle pour la station dakar-yoff:
- MSE: 0.0179
- RMSE: 0.1338
- MAE: 0.0875
- F1-Score: 0.7765

Performance du modèle pour la station kaolack:
- MSE: 0.0149
- RMSE: 0.1219
- MAE: 0.0703
- F1-Score: 0.8751

Performance du modèle pour la station kedougou:
- MSE: 0.0188
- RMSE: 0.1372
- MAE: 0.0950
- F1-Score: 0.7496

Performance du modèle pour la station saint-louis :
- MSE: 0.0166
- RMSE: 0.1288
- MAE: 0.0921
- F1-Score: 0.8471

Performance du modèle pour la station tamba:
- MSE: 0.0288
- RMSE: 0.1697
- MAE: 0.0936
- F1-Score: 0.8055
```

Figure 4 : Evaluations des performances selon les stations (1)

```
Performance du modèle pour la station thies:
- MSE: 0.0217
- RMSE: 0.1472
- MAE: 0.1023
- F1-Score: 0.7279

Performance du modèle pour la station ziguinchor:
- MSE: 0.0193
- RMSE: 0.1391
- MAE: 0.0955
- F1-Score: 0.7880
```

Figure 5 : Evaluations des performances selon les stations (2)

Les performances du modèle pour différentes stations météorologiques sont évaluées en utilisant plusieurs métriques : MSE (Mean Squared Error), RMSE (Root Mean Squared Error), MAE (Mean Absolute Error), interprétons les performances de notre modèle

1. **Dakar-Yoff :**

- **MSE** : 0.0179
- **RMSE** : 0.1338
- **MAE** : 0.0875
- **Interprétation** : Le modèle a une erreur quadratique moyenne relativement faible, indiquant une bonne performance. Le MAE est également bas, ce qui signifie que les prédictions sont globalement proches des valeurs réelles.

2. **Kaolack :**

- **MSE** : 0.0149
- **RMSE** : 0.1219
- **MAE** : 0.0703
- **Interprétation** : La station de Kaolack présente des performances très solides avec le plus faible MAE parmi les stations, ce qui signifie que les prédictions sont très précises.

3. **Kédougou :**

- **MSE** : 0.0188
- **RMSE** : 0.1372
- **MAE** : 0.0950
- **Interprétation** : Le modèle pour Kédougou a un MSE un peu plus élevé par rapport à d'autres stations, ce qui indique une légère augmentation de l'erreur. Le MAE est également plus élevé, suggérant des prédictions moins précises.

4. **Saint-Louis :**

- **MSE** : 0.0166
- **RMSE** : 0.1288
- **MAE** : 0.0921

- **Interprétation** : Le modèle pour Saint-Louis montre une bonne performance globale avec des erreurs relativement basses.

5. **Tamba** :

- **MSE** : 0.0288
- **RMSE** : 0.1697
- **MAE** : 0.0936
- **Interprétation** : La station de Tamba a le plus haut MSE et RMSE, ce qui indique que le modèle a des prédictions moins précises pour cette station. Cependant, le MAE reste modéré.

6. **Thiès** :

- **MSE** : 0.0217
- **RMSE** : 0.1472
- **MAE** : 0.1023
- **Interprétation** : Thiès montre un MSE et MAE plus élevés, ce qui signifie des prédictions moins précises.

7. **Ziguinchor** :

- **MSE** : 0.0193
- **RMSE** : 0.1391
- **MAE** : 0.0955

Interprétation : Ziguinchor présente des erreurs modérées, montre des performances raisonnables en termes de classification.

Résumé général :

- **Kaolack** a les meilleures performances globales avec le plus faible MAE
- **Tamba** montre les performances les plus faibles avec le plus haut MSE et RMSE.

Globalement, la performance du modèle varie selon les stations, mais elle reste bonne pour la plupart des stations, avec quelques exceptions.

Navigation

Choisissez une option

- ☐ Accueil
- ☒ Prédictions
- ☐ Exploration des données
- ☐ Comparaison historique

Sélectionnez une station

dakar-yoff

Date de début

2025/07/01

Nombre de mois à prédire

1 2 12

Prédire

Date de début: 2025-07-01

Nombre de mois prédit: 2

	Évaporation (mm)	Vitesse du vent (m/s)	Insolation (h)	Précipitations (mm)	Temp. moy. r
2025-07-01 00:00:00	2.1659	3.1891	7.176	150.0671	
2025-08-01 00:00:00	2.2654	3.2268	7.6865	98.0225	

Graphiques des prévisions



Figure 6 : Visualisation des résultats

Le projet a démontré la viabilité de l'utilisation de modèles d'intelligence artificielle pour les prévisions météorologiques, offrant des performances prometteuses par rapport aux méthodes traditionnelles. Les résultats obtenus montrent que l'IA peut jouer un rôle crucial dans la précision et rapidité des prévisions, tout en offrant des possibilités d'amélioration continue grâce à l'intégration de nouvelles données et techniques.

5.3 II. Outils de développement et de déploiement

5.3.1 Environnement de Développement

L'environnement de développement a été configuré pour répondre aux exigences de création d'un modèle de machine learning robuste tout en facilitant son déploiement interactif à l'aide de Streamlit.

- **Langages Utilisés :** Python a été utilisé comme principal langage de programmation en raison de sa large adoption dans la communauté de l'IA et de la data science, ainsi que pour ses nombreuses bibliothèques adaptées au machine learning.

- **IDE et Notebooks** : Le développement a commencé avec Google Colab pour le prototypage rapide et les expérimentations, avant de passer à un environnement plus structuré avec Visual Studio Code pour un développement approfondi.

5.3.2 Technologies de Développement

La sélection des technologies a été faite pour maximiser l'efficacité du développement et assurer une intégration fluide.

- **Frameworks de Machine Learning** : Le projet a tiré parti de Keras pour la conception et l'entraînement des modèles de réseaux neuronaux, optimisés pour la gestion des données temporelles complexes liées à la météo.
- **Bibliothèques de Traitement de Données** : Les bibliothèques Pandas et NumPy ont été utilisées pour manipuler et transformer les données météorologiques, tandis que Matplotlib et Seaborn ont été utilisés pour visualiser les résultats.

5.3.3 Architecture de la Solution

L'architecture de la solution a été conçue pour être à la fois robuste et facilement déployable.

- **Modélisation** : Un réseau de neurones récurrent (RNN) a été utilisé pour capturer les tendances temporelles dans les données météorologiques. Le modèle a été entraîné sur des ensembles de données historiques et validé sur des ensembles de test.
- **Interface Utilisateur avec Streamlit** : L'interface utilisateur a été développée avec Streamlit, permettant aux utilisateurs finaux d'interagir avec le modèle de manière intuitive. Les utilisateurs peuvent entrer des données, demander des prévisions, et visualiser les résultats en temps réel grâce à l'interface web générée par Streamlit.

5.3.4 Architecture et Services du Déploiement

Le déploiement a été conçu pour être simple et efficace, en utilisant Streamlit pour créer une interface utilisateur accessible via un navigateur web, sans nécessiter de configurations complexes côté utilisateur.

- **Déploiement avec Streamlit** : Streamlit a été choisi pour le déploiement de l'application en raison de sa simplicité d'utilisation et de son efficacité pour créer des interfaces interactives sans avoir besoin d'une expertise approfondie en développement web. L'application a été déployée sur une instance cloud, ce qui permet aux utilisateurs d'y accéder via un simple lien web.

- **Lien d'accès :** <https://senegalforecasting.streamlit.app/>

6 CONCLUSION GENERALE

6.1 Bilans de l'Étude

L'étude et le développement d'un modèle d'intelligence artificielle pour les prévisions météorologiques ont permis de mettre en lumière la puissance des techniques de machine learning dans le traitement et l'analyse de données complexes. Le projet a réussi à démontrer que l'IA peut non seulement égaler, mais souvent surpasser, les méthodes traditionnelles en matière de précision des prévisions. Grâce à une architecture bien pensée et à l'utilisation d'outils modernes comme Keras, TensorFlow et Streamlit, nous avons pu construire un modèle robuste et scalable capable de fournir des prévisions météorologiques en temps réel.

Le travail réalisé a permis de répondre efficacement aux besoins initialement spécifiés, en développant une solution capable de traiter de grands volumes de données, d'apprendre à partir de ces données, et de fournir des prévisions précises. Les résultats obtenus sont encourageants, avec une amélioration notable de la précision des prévisions par rapport aux approches classiques. L'intégration de l'application via Streamlit a permis de rendre le modèle accessible à un large public, simplifiant ainsi l'interaction avec le système et permettant une adoption plus large.

6.2 Perspectives

Malgré les succès obtenus, plusieurs axes d'amélioration et d'approfondissement peuvent être envisagés pour le futur :

1. **Amélioration des Données :** L'intégration de nouvelles sources de données, telles que les images satellites, les données radar, ou des informations en temps réel provenant

de capteurs IoT, pourrait enrichir le modèle et améliorer la précision des prévisions, en particulier pour les phénomènes météorologiques rares ou extrêmes.

2. **Modèles d'Ensemble** : Le développement et l'intégration de modèles d'ensemble, combinant plusieurs approches de machine learning, pourraient offrir une meilleure robustesse face à la variabilité des données météorologiques, en minimisant les erreurs de prédiction.
3. **Déploiement à Grande Échelle** : L'adoption d'une infrastructure cloud plus avancée, avec des capacités de calcul distribué plus importantes, permettrait de déployer le modèle sur une échelle encore plus large, assurant des prévisions météorologiques pour des régions plus vastes et avec une granularité plus fine.

En somme, ce projet ouvre la voie à de nombreuses opportunités pour l'optimisation des prévisions météorologiques grâce à l'IA. Les avancées réalisées jusqu'à présent constituent une base solide pour des développements futurs qui, à terme, pourraient transformer radicalement la manière dont nous prévoyons et réagissons aux conditions météorologiques.

REFERENCES :

<https://otexts.com/fpp2/intro.html>

<https://www.anacim.sn/>