

Dakar Institute of Technology



Habilitation n°3386-21 FEV.2024

Domaine : Sciences et Technologies

Département : Informatique

Spécialité : Intelligence Artificielle

Projet Informatique

Présenté par :

[Votre Nom Complet]

SUJET :

Estimation de la valeur des biens immobiliers résidentiels au
Sénégal : prédiction des prix, optimisation des paramètres
d'entraînement et interface graphique interactive

Soutenu le : .../.../...

Année Académique : 2025-2026

Dédicace

À ma famille, pour son soutien indéfectible tout au long de ce projet.

Remerciements

Je tiens à remercier l'ensemble du corps enseignant du Dakar Institute of Technology pour l'encadrement apporté tout au long de ce projet informatique, ainsi que toute personne ayant contribué, de près ou de loin, à sa réalisation.

Glossaire

FCFA Franc de la Communauté Financière Africaine, monnaie utilisée au Sénégal.

Modèle hédonique Modèle économétrique postulant que le prix d'un bien composite (ex. un logement) se décompose en la somme des valeurs implicites de ses caractéristiques (surface, localisation, etc.).

RMSE *Root Mean Squared Error* — racine de l'erreur quadratique moyenne, métrique d'évaluation pénalisant fortement les grandes erreurs.

MAE *Mean Absolute Error* — erreur absolue moyenne entre les valeurs prédites et réelles.

MAPE *Mean Absolute Percentage Error* — erreur moyenne exprimée en pourcentage de la valeur réelle.

R^2 Coefficient de détermination — part de la variance de la variable cible expliquée par le modèle.

Random Forest Algorithme d'apprentissage ensembliste combinant un grand nombre d'arbres de décision entraînés sur des sous-échantillons aléatoires des données.

XGBoost *Extreme Gradient Boosting* — algorithme de boosting de gradient optimisé, construisant les arbres de façon séquentielle pour corriger les erreurs des précédents.

MLP *Multi-Layer Perceptron* — réseau de neurones artificiels à propagation avant, composé d'une ou plusieurs couches cachées.

Hyperparamètre Paramètre de configuration d'un modèle fixé avant l'entraînement (ex. profondeur d'un arbre, taux d'apprentissage), par opposition aux paramètres appris à partir des données.

One-Hot Encoding Technique d'encodage transformant une variable catégorielle en un ensemble de variables binaires indicatrices.

Web scraping Technique de collecte automatisée de données publiées sur des pages web.

Liste des figures

4.1	Distribution des prix (échelle brute et échelle logarithmique)	11
4.2	Prix par type de bien (maison / appartement)	12
4.3	Prix médian par quartier (15 quartiers les plus représentés)	13
4.4	Prix en fonction de la surface, par type de bien	14
4.5	Prix en fonction du nombre de chambres	15
4.6	Corrélations entre variables numériques	15
4.7	Comparaison visuelle des modèles (RMSE, MAPE, R^2)	16
4.8	Importance des variables — Random Forest et XGBoost	16

Liste des tableaux

3.1	Espaces d'hyperparamètres explorés par modèle	9
4.1	Performances comparées des modèles sur le jeu de test	12

Résumé

Ce projet informatique de Master 1 présente le développement d'un système d'estimation automatique de la valeur des biens immobiliers résidentiels (maisons et appartements) au Sénégal, à partir de techniques d'apprentissage automatique. L'objectif est double : d'une part comparer plusieurs modèles de prédiction en optimisant systématiquement leurs hyperparamètres, et d'autre part rendre ces résultats accessibles à travers une interface graphique interactive.

En l'absence de jeu de données immobilier sénégalais existant, un corpus de 660 annonces de vente a été collecté par extraction automatisée (*web scraping*) depuis la plateforme Expat-Dakar, couvrant l'ensemble du territoire national. Après nettoyage (suppression des prix non exploitables et des biens hors périmètre résidentiel unitaire), un jeu de données de 603 annonces a été retenu, décrit par la surface, le nombre de chambres, le type de bien et le quartier.

Quatre modèles ont été entraînés et comparés : une régression linéaire (référence), une forêt aléatoire (*Random Forest*), un modèle de *gradient boosting* (XGBoost), et un réseau de neurones multicouches (MLP) — les trois derniers optimisés par recherche aléatoire d'hyperparamètres avec validation croisée. Le modèle Random Forest optimisé obtient les meilleures performances sur le jeu de test (MAE de 73,3 millions FCFA, MAPE de 34,0 %, R^2 de 0,751), devançant XGBoost et le réseau de neurones — un résultat cohérent avec la littérature sur des jeux de données tabulaires de taille modeste.

Une application interactive développée avec Streamlit permet enfin d'estimer le prix d'un bien à partir de ses caractéristiques, d'explorer le jeu de données et de comparer visuellement les performances des différents modèles.

Mots-clés : immobilier, apprentissage automatique, optimisation d'hyperparamètres, Random Forest, XGBoost, réseau de neurones, Sénégal, Streamlit.

Abstract

This Master 1 computer science project presents the development of an automatic valuation system for residential real estate (houses and apartments) in Senegal, based on machine learning techniques. The goal is twofold : to compare several prediction models through systematic hyperparameter optimization, and to make the results accessible through an interactive graphical interface.

In the absence of any existing Senegalese real-estate dataset, a corpus of 660 sale listings was collected through automated web scraping from the Expat-Dakar platform, covering the whole country. After cleaning (removal of non-exploitable prices and of properties outside the single-unit residential scope), a dataset of 603 listings was retained, described by surface area, number of bedrooms, property type, and neighborhood.

Four models were trained and compared : a linear regression (baseline), a Random Forest, a gradient boosting model (XGBoost), and a multi-layer perceptron (MLP) neural network — the latter three tuned through randomized hyperparameter search with cross-validation. The optimized Random Forest achieved the best performance on the test set (MAE of 73.3 million FCFA, MAPE of 34.0%, R^2 of 0.751), outperforming both XGBoost and the neural network — a result consistent with the literature on modestly sized tabular datasets.

An interactive web application built with Streamlit allows users to estimate a property's price from its characteristics, explore the dataset, and visually compare model performance.

Keywords : real estate, machine learning, hyperparameter optimization, Random Forest, XGBoost, neural network, Senegal, Streamlit.

Sommaire

Introduction

Chapitre I — État de l’art

Chapitre II — Analyse de besoins et méthodologie

Chapitre III — Implémentation

Conclusion générale

Bibliographie et webographie

Annexes

Chapitre 1

Introduction

1.1 Contexte et justification

Le secteur immobilier occupe une place croissante dans l'économie sénégalaise, porté par l'urbanisation rapide de l'agglomération dakaroise et le développement de pôles urbains secondaires (Diamniadio, Thiès, Mbour). Pourtant, contrairement à des marchés plus matures où des bases de données de transactions publiques (cadastre ouvert, historiques notariaux) permettent une estimation relativement transparente des prix, le marché sénégalais souffre d'un déficit important d'information centralisée : les prix affichés sur les plateformes d'annonces sont négociables, très hétérogènes d'un quartier à l'autre, et aucune base de données publique ne permet aujourd'hui d'objectiver la valeur d'un bien à partir de ses caractéristiques.

Cette opacité pénalise autant les particuliers (acheteurs, vendeurs) que les professionnels (agences immobilières, banques accordant des prêts hypothécaires) qui doivent s'appuyer sur l'expertise de terrain ou sur la méthode dite « des comparables », intrinsèquement subjective et chronophage. L'essor de l'apprentissage automatique (*machine learning*) et la multiplication des données disponibles en ligne — notamment via les plateformes d'annonces immobilières — ouvrent la voie à des modèles d'estimation automatique de la valeur des biens, communément appelés *Automated Valuation Models* (AVM) dans la littérature.

C'est dans ce contexte que s'inscrit ce projet informatique : construire, à partir de données réellement observées sur le marché sénégalais, un modèle capable d'estimer le prix d'un bien résidentiel (maison ou appartement), tout en explorant systématiquement l'apport de l'optimisation des hyperparamètres d'entraînement sur la qualité des prédictions, et en rendant ce modèle accessible via une interface graphique interactive plutôt que réservé à un usage technique.

1.2 Objectifs de la recherche

Ce projet poursuit trois objectifs principaux :

1. **Constituer un jeu de données exploitable** sur les prix des biens immobiliers

résidentiels au Sénégal, en l'absence de source publique existante, par collecte automatisée de données d'annonces réelles.

2. **Comparer plusieurs familles de modèles** de prédiction du prix (régression linéaire, méthodes ensemblistes à base d'arbres, réseau de neurones), en optimisant systématiquement leurs hyperparamètres d'entraînement par recherche aléatoire avec validation croisée, afin d'identifier l'approche la plus pertinente au regard du volume de données disponible.
3. **Développer une interface graphique interactive** permettant à un utilisateur non technique d'obtenir une estimation de prix à partir des caractéristiques d'un bien, et d'explorer visuellement les données et les performances des modèles.

1.3 Structure du projet informatique

Ce document est organisé en trois chapitres. Le **Chapitre I** dresse un état de l'art du domaine, à la fois sur les méthodes classiques d'évaluation immobilière et sur les travaux de recherche appliquant l'apprentissage automatique à ce problème, en identifiant les zones encore peu explorées — en particulier dans le contexte ouest-africain. Le **Chapitre II** détaille l'analyse des besoins, les sources de données mobilisées, le processus de collecte et de pré-traitement, ainsi que la méthodologie de modélisation et d'évaluation retenue. Le **Chapitre III** présente l'implémentation réalisée : l'analyse exploratoire des données, les résultats obtenus pour chaque modèle, leur interprétation et leur mise en perspective avec la littérature, ainsi que les outils et l'architecture de la solution développée, incluant l'interface graphique interactive. Une conclusion générale dresse le bilan du projet et propose des perspectives d'amélioration.

1.4 Conclusion

Ce chapitre introductif a situé le projet dans son contexte : un marché immobilier sénégalais en expansion mais peu documenté, pour lequel les techniques d'apprentissage automatique offrent une opportunité concrète d'objectiver l'estimation des prix. Les trois objectifs — collecte de données, modélisation optimisée, restitution interactive — structurent l'ensemble de la démarche présentée dans les chapitres suivants.

Chapitre 2

État de l’art

2.1 État de l’art sur le domaine d’application

L’estimation de la valeur d’un bien immobilier repose historiquement sur le **modèle hédonique**, formalisé par Rosen [5]. Ce modèle postule qu’un bien composite comme un logement peut être décomposé en un ensemble de caractéristiques (surface, nombre de pièces, localisation, qualité de construction, etc.), chacune contribuant implicitement au prix final observé sur le marché. Cette approche, traditionnellement opérationnalisée par une régression linéaire multiple, reste la référence en économie urbaine et sous-tend encore la méthode dite « des comparables » utilisée par les agents immobiliers et notaires : le prix d’un bien est estimé par analogie avec des transactions récentes de biens aux caractéristiques proches.

Cette approche présente cependant des limites bien documentées : elle suppose des relations linéaires entre caractéristiques et prix, peine à capturer les interactions complexes entre variables (par exemple, l’effet de la surface sur le prix n’est pas le même selon le quartier), et dépend fortement de la disponibilité de transactions comparables récentes — une condition difficile à remplir dans un marché comme celui du Sénégal, où les données de transactions ne sont pas centralisées.

L’essor de l’apprentissage automatique a permis l’émergence des *Automated Valuation Models* (AVM), qui remplacent ou complètent le modèle hédonique classique par des algorithmes capables de capturer des relations non linéaires et des interactions complexes entre caractéristiques, sans hypothèse a priori sur la forme fonctionnelle de la relation entre les variables explicatives et le prix.

2.2 État de l’art sur les travaux de recherche pertinents liés au sujet

Plusieurs familles de modèles ont été appliquées à la prédiction de prix immobiliers dans la littérature récente.

Les **méthodes ensemblistes à base d’arbres de décision** occupent une place

centrale. Breiman [1] a introduit le *Random Forest*, qui combine un grand nombre d'arbres entraînés sur des sous-échantillons aléatoires des données et des variables, réduisant la variance par rapport à un arbre unique. Chen and Guestrin [2] a ensuite proposé XGBoost, une implémentation optimisée du *gradient boosting*, qui construit les arbres de façon séquentielle pour corriger les erreurs des précédents. Appliqués à la prédiction de prix immobiliers, Truong et al. [7] comparent régression linéaire, k plus proches voisins, CART et méthodes ensemblistes, et montrent la supériorité systématique des approches ensemblistes sur les modèles linéaires classiques. Sharma et al. [6] comparent plus spécifiquement régression linéaire multiple, SVR, Random Forest, MLP et XGBoost sur le jeu de données Ames Housing (Iowa, États-Unis) et concluent à la supériorité de XGBoost, avec un R^2 proche de 0,89 — un résultat obtenu toutefois sur un jeu de données nettement plus riche (79 variables descriptives) que celui mobilisé dans ce projet.

Les **réseaux de neurones profonds** ont également été explorés. Yazdani [8] comparent modèles hédoniques classiques, méthodes de machine learning (Random Forest, k plus proches voisins) et de deep learning pour la prédiction de prix immobiliers, et observent que l'avantage des réseaux de neurones dépend fortement du volume de données disponible : sur des jeux de données de taille modeste, les méthodes ensemblistes à base d'arbres restent souvent compétitives, voire supérieures, aux architectures de deep learning.

Enfin, un travail directement pertinent pour le contexte de ce projet est celui de Nwankwo et al. [3], qui appliquent plusieurs modèles de machine learning (dont un réseau de neurones artificiel et XGBoost) à la prédiction des prix immobiliers à Lagos, au Nigeria — un marché ouest-africain partageant avec le Sénégal des caractéristiques structurelles proches (données peu centralisées, forte hétérogénéité des annonces en ligne). Les auteurs confirment l'efficacité des approches ensemblistes et des réseaux de neurones dans ce contexte, tout en soulignant le rôle déterminant des variables de localisation.

L'écosystème logiciel de ce projet s'appuie par ailleurs sur la bibliothèque scikit-learn [4], largement utilisée dans la littérature pour l'implémentation reproductible de pipelines de machine learning.

2.3 Identification des zones de recherche manquantes liées au sujet

Cette revue de la littérature met en évidence plusieurs zones encore peu explorées, que ce projet cherche en partie à adresser :

- **Absence de données et de travaux spécifiques au Sénégal.** Contrairement au Nigeria [3] ou aux marchés occidentaux disposant de jeux de données de référence (Ames Housing, Boston Housing), aucun jeu de données immobilier sénégalais n'est publiquement disponible, et aucun travail de recherche appliquant le machine

learning à ce marché n'a été identifié au moment de la rédaction de ce document.

- **Comparaison systématique méthodes ensemblistes / deep learning sur données ouest-africaines restreintes.** La littérature suggère que l'avantage du deep learning sur les méthodes ensemblistes dépend du volume de données [8], mais ce compromis n'a pas été quantifié sur un marché immobilier africain à faible volume de données structurées.
- **Accessibilité des outils produits.** La grande majorité des travaux cités se limitent à une évaluation académique des modèles, sans restitution accessible à un utilisateur non technique — un manque que ce projet adresse via le développement d'une interface graphique interactive.

2.4 Conclusion

Le modèle hédonique reste le cadre théorique de référence pour l'estimation immobilière, mais les approches d'apprentissage automatique — en particulier les méthodes ensemblistes à base d'arbres — s'imposent progressivement comme des alternatives plus performantes, sous réserve d'un volume de données suffisant. Le contexte sénégalais, marqué par l'absence de données publiques structurées, constitue à la fois la principale difficulté méthodologique de ce projet et sa principale zone de contribution : la constitution d'un premier jeu de données exploitable et la comparaison empirique de plusieurs familles de modèles sur ce marché spécifique.

Chapitre 3

Analyse de besoins et méthodologie

3.1 I. Spécification des besoins et des données

3.1.1 Analyse et spécification des besoins

Les utilisateurs finaux visés par ce projet sont les particuliers souhaitant estimer la valeur d'un bien avant une transaction, ainsi que les professionnels (agences immobilières) souhaitant disposer d'un outil d'aide à la décision rapide.

Besoins fonctionnels :

- Estimer le prix d'un bien résidentiel (maison ou appartement) à partir de ses caractéristiques principales (type, quartier, surface, nombre de chambres).
- Comparer les résultats de plusieurs modèles pour un même bien.
- Explorer visuellement le jeu de données ayant servi à l'entraînement (distribution des prix, prix par quartier, etc.).
- Visualiser les performances comparées des modèles.

Besoins non fonctionnels :

- Accessibilité via une interface web, sans compétence technique requise.
- Reproductibilité du pipeline de collecte, nettoyage et entraînement.
- Transparence sur la marge d'erreur des estimations produites.

3.1.2 Sources de données

Une recherche préalable a permis d'écarter plusieurs pistes de données existantes :

- aucun jeu de données immobilier sénégalais n'est disponible sur les plateformes usuelles (Kaggle) ;
- l'Agence Nationale de la Statistique et de la Démographie (ANSD) publie des indices macro-économiques du secteur (indice du coût de la construction, indice des prix des matériaux), mais aucune donnée au niveau transaction ;
- aucun portail cadastral ouvert, comparable à celui existant en France, n'est disponible pour le Sénégal.

Faute de source structurée existante, les données ont été collectées par extraction automatisée (*web scraping*) depuis **Expat-Dakar** (<https://www.expat-dakar.com/>),

plateforme d'annonces généralistes hébergeant plusieurs milliers d'annonces immobilières actives. Ce choix a été validé par une double vérification : la structure des pages (attributs `data-t-listing_*` intégrés directement dans le HTML, encodant prix, type de bien, localisation et identifiant de façon structurée) permet une extraction fiable, et le fichier `robots.txt` du site autorise l'accès aux pages d'annonces (seuls les répertoires `/admin/`, `/compte/` et `/cdn-cgi/` sont exclus).

3.1.3 Processus de collecte

La collecte a été réalisée avec un script Python (`src/scrapper.py`) s'appuyant sur les bibliothèques `requests` et `BeautifulSoup`. Le périmètre retenu couvre :

- les annonces de **vente** (à l'exclusion de la location, pour ne pas mélanger deux marchés aux dynamiques de prix différentes) ;
- les catégories **maisons à vendre** et **appartements à vendre** (à l'exclusion des terrains nus et des biens commerciaux, hors périmètre résidentiel) ;
- l'ensemble du territoire sénégalais (pas de restriction géographique a priori).

Pour chaque annonce, les champs suivants sont extraits : identifiant, titre, catégorie, prix (FCFA), quartier, ville/région, nombre de chambres, surface (m²), date de publication et URL. La pagination est parcourue jusqu'à réception d'une page vide ou d'une réponse HTTP 404 signalant la fin des résultats, avec un délai d'une seconde et demie entre chaque requête afin de limiter la charge sur le serveur cible. La collecte a produit **660 annonces brutes** (330 maisons, 330 appartements), sans doublon.

3.1.4 Pré-processing des données

Le nettoyage du jeu de données brut (détaillé et exécuté dans le notebook `01_eda_nettoyage.ipynb`) comprend les étapes suivantes :

1. **Suppression des prix non exploitables.** Un seuil minimal de 5 000 000 FCFA a été retenu après inspection manuelle des valeurs basses : en deçà, les annonces correspondent systématiquement à des incohérences flagrantes plutôt qu'à de véritables biens bon marché — par exemple, une villa de 1000 m² au quartier des Ngor (où le prix moyen dépasse 200 millions FCFA) affichée à 1,5 million FCFA, probablement un prix « sur demande » ou une mensualité mal étiquetée comme prix total. Cette étape a supprimé 43 annonces.
2. **Exclusion des biens hors périmètre résidentiel unitaire.** Les annonces présentant une surface supérieure à 2000 m² ou plus de 15 chambres ont été exclues, ces valeurs correspondant vraisemblablement à des immeubles entiers plutôt qu'à un logement individuel. Cette étape a supprimé 14 annonces supplémentaires.

3. **Imputation des valeurs manquantes.** Les champs `surface_m2` et `bedrooms`, absents respectivement pour 16,4 % et 23,3 % des annonces (non systématiquement renseignés par les vendeurs), ont été imputés par la médiane du groupe (catégorie $\times$ ville/région), avec repli sur la médiane globale en l'absence de groupe suffisant.
4. **Regroupement des quartiers rares.** Le jeu de données comporte 92 quartiers distincts pour 603 lignes, avec une forte hétérogénéité de représentation. Les quartiers comptant moins de 5 annonces ont été regroupés dans une catégorie **Autre** afin de limiter le risque de surapprentissage lors de l'encodage catégoriel, ramenant la cardinalité effective à 34 catégories.

Le jeu de données final compte **603 annonces**, décrites par : le type de bien (catégorie), le quartier (regroupé), la surface et le nombre de chambres, pour une cible à prédire (le prix en FCFA).

3.2 II. Méthodologie

3.2.1 Choix des algorithmes et modèles

Quatre modèles ont été retenus et comparés :

1. **Régression linéaire** — modèle de référence, non optimisé, permettant de juger de l'apport réel des modèles plus complexes.
2. **Random Forest** [1] — méthode ensembliste à base d'arbres, optimisée.
3. **XGBoost** [2] — méthode de *gradient boosting*, optimisée.
4. **MLP (Multi-Layer Perceptron)** — réseau de neurones artificiel, optimisé, représentant l'approche deep learning du projet.

3.2.2 Justification des choix

La régression linéaire sert de ligne de base simple et interprétable, dans la tradition du modèle hédonique. Random Forest et XGBoost ont été retenus car la littérature (§ 2.2) montre leur supériorité constante sur les modèles linéaires pour ce type de problème, tout en restant robustes sur des jeux de données de taille modeste. Le MLP a été retenu pour répondre explicitement à l'objectif de comparaison avec une approche de deep learning formulé dans le sujet du projet.

Un choix d'implémentation mérite d'être justifié : le réseau de neurones a été implémenté avec la classe `MLPRegressor` de scikit-learn plutôt qu'avec un framework de deep learning dédié (TensorFlow/Keras, utilisé par exemple dans des projets de prévision météorologique sur des séries beaucoup plus longues). Avec environ 600 lignes d'entraînement, un framework complet (gestion GPU, callbacks avancés) n'apporte aucun bénéfice ; un perceptron

multicouche reste le niveau de complexité approprié, tout en permettant une véritable optimisation d'hyperparamètres (architecture, régularisation, taux d'apprentissage).

3.2.3 Paramètres et configuration

Chaque modèle (à l'exception de la régression linéaire) a été optimisé par `RandomizedSearchCV` (recherche aléatoire, 30 combinaisons tirées, validation croisée à 5 plis mélangés), avec comme métrique d'optimisation l'erreur absolue moyenne négative (`neg_mean_absolute_error`) calculée sur la cible transformée en logarithme (voir § 3.5). Les espaces de recherche retenus sont résumés dans le tableau 3.1.

TABLE 3.1 – Espaces d'hyperparamètres explorés par modèle

Modèle	Hyperparamètre	Valeurs explorées
Random Forest	<code>n_estimators</code>	100, 200, 300, 400, 500
	<code>max_depth</code>	None, 5, 10, 15, 20, 30
	<code>min_samples_split</code>	2, 5, 10
	<code>min_samples_leaf</code>	1, 2, 4
	<code>max_features</code>	<code>sqrt</code> , <code>log2</code> , None
XGBoost	<code>n_estimators</code>	100, 200, 300, 400
	<code>max_depth</code>	3, 4, 5, 6, 8
	<code>learning_rate</code>	0.01, 0.03, 0.05, 0.1, 0.2
	<code>subsample</code>	0.6, 0.8, 1.0
	<code>colsample_bytree</code>	0.6, 0.8, 1.0
	<code>reg_alpha</code>	0, 0.1, 1
	<code>reg_lambda</code>	1, 1.5, 2
MLP	<code>hidden_layer_sizes</code>	(32,), (64,), (64,32), (128,64), (64,64,32)
	<code>alpha</code>	0.0001, 0.001, 0.01, 0.1
	<code>learning_rate_init</code>	0.0005, 0.001, 0.005, 0.01
	<code>activation</code>	<code>relu</code> , <code>tanh</code>

3.2.4 Évaluation des performances

L'évaluation est réalisée sur un jeu de test indépendant, obtenu par partitionnement aléatoire (80 % entraînement / 20 % test, soit 482 et 121 annonces respectivement), non utilisé lors de l'optimisation des hyperparamètres.

3.2.5 Métriques utilisées

Quatre métriques complémentaires sont calculées, après retransformation des prédictions de l'échelle logarithmique vers le FCFA :

- **RMSE** (*Root Mean Squared Error*) : $\sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}$ — pénalise fortement les grandes erreurs.

- **MAE** (*Mean Absolute Error*) : $\frac{1}{n} \sum_i |y_i - \hat{y}_i|$ — erreur moyenne absolue, en FCFA.
- **MAPE** (*Mean Absolute Percentage Error*) : $\frac{100}{n} \sum_i \left| \frac{y_i - \hat{y}_i}{y_i} \right|$ — erreur moyenne relative, la plus interprétable pour un public non technique.
- R^2 : part de variance de la cible expliquée par le modèle.

3.2.6 Protocole d'évaluation

La distribution des prix étant fortement asymétrique (quelques biens haut de gamme, cf. Figure 4.1), tous les modèles sont entraînés sur la cible transformée en $\log(1 + \text{prix})$, une pratique usuelle en modélisation de prix immobiliers qui stabilise la variance et améliore la performance des modèles linéaires et des réseaux de neurones, sans pénaliser les méthodes à base d'arbres, insensibles aux transformations monotones. Les prédictions sont retransformées en FCFA (fonction exponentielle inverse) avant le calcul des métriques finales, afin de conserver une interprétation directe des résultats.

3.3 Conclusion

Ce chapitre a détaillé la démarche méthodologique retenue : faute de données existantes, un jeu de données a été constitué par extraction automatisée puis nettoyé selon des règles justifiées et quantifiées ; quatre modèles ont été sélectionnés pour couvrir à la fois l'approche hédonique classique, les méthodes ensemblistes et le deep learning, avec un protocole d'optimisation et d'évaluation homogène permettant une comparaison rigoureuse, présentée au chapitre suivant.

Chapitre 4

Implémentation

4.1 Résultats

4.1.1 Analyse exploratoire des données

Le jeu de données nettoyé compte 603 annonces et 11 colonnes (identifiant, titre, catégorie, prix, devise, quartier, ville/région, nombre de chambres, surface, date de publication, URL). La répartition géographique est fortement concentrée : 515 annonces à Dakar (85,4 %), 84 à Thiès (13,9 %), et seulement 4 annonces réparties entre Kaolack, Saint-Louis et d'autres localités. Cette concentration reflète la structure même du marché des annonces en ligne au Sénégal, très majoritairement actif dans la capitale, et constitue une limite explicite à la capacité de généralisation du modèle en dehors de Dakar et Thiès, discutée en § 4.1.4.




FIGURE 4.1 – Distribution des prix (échelle brute et échelle logarithmique)

La distribution des prix (Figure 4.1) est fortement asymétrique à droite, avec une majorité de biens sous 300 millions FCFA et une longue traîne de biens haut de gamme. Cette asymétrie justifie la transformation logarithmique de la cible retenue en § 3.6.

Le prix médian varie fortement selon le quartier (Figure 4.3), les quartiers résidentiels haut de gamme de Dakar (Almadies, Ngor, Mermoz) affichant des médianes nettement supérieures à celles des quartiers périphériques — un résultat cohérent avec la littérature sur le rôle central de la localisation dans la formation des prix [3].




FIGURE 4.2 – Prix par type de bien (maison / appartement)

La surface (Figure 4.4) présente la relation la plus nette avec le prix, ce que confirme la matrice de corrélation (Figure 4.6). Le nombre de chambres (Figure 4.5) a un effet positif mais plus diffus : des biens au nombre de chambres identique peuvent présenter des surfaces, et donc des prix, très différents.

4.1.2 Résultats des modèles

Le tableau 4.1 présente les performances des quatre modèles sur le jeu de test (121 annonces), après optimisation des hyperparamètres pour Random Forest, XGBoost et le MLP.

TABLE 4.1 – Performances comparées des modèles sur le jeu de test

Modèle	RMSE (FCFA)	MAE (FCFA)	MAPE (%)	R^2
Régression linéaire	148 156 086	89 002 102	39,7	0,571
Random Forest (optimisé)	112 897 339	73 325 765	34,0	0,751
XGBoost (optimisé)	125 455 687	79 242 132	37,7	0,692
MLP (optimisé)	125 968 083	82 416 154	37,0	0,690

Les meilleurs hyperparamètres retenus par la recherche aléatoire sont : pour Random Forest, `n_estimators=400`, `max_depth=30`, `min_samples_split=5`, `min_samples_leaf=1`, `max_features='log2'` ; pour XGBoost, `n_estimators=300`, `max_depth=3`, `learning_rate=0.1`, `subsample=1.0`, `colsample_bytree=0.6`, `reg_alpha=0.1`, `reg_lambda=1` ; pour le MLP, `hidden_layer_sizes=(32,)`, `activation='tanh'`, `alpha=0.1`, `learning_rate_init=0.005`.




FIGURE 4.3 – Prix médian par quartier (15 quartiers les plus représentés)

4.1.3 Interprétation des résultats

Random Forest domine nettement les trois autres modèles sur les quatre métriques (Figure 4.7), avec un gain de MAE de près de 18 % par rapport à la régression linéaire de référence, et de 7 à 11 % par rapport à XGBoost et au MLP malgré l’optimisation appliquée à ces derniers. Ce résultat confirme l’apport net des méthodes ensemblistes par rapport à l’approche hédonique linéaire classique.

L’analyse de l’importance des variables (Figure 4.8) confirme les observations de l’analyse exploratoire : la surface est systématiquement la variable la plus déterminante, suivie par les indicatrices de quartier les plus fréquentes (Almadies, Ngor, Mermoz), tandis que le nombre de chambres contribue de façon plus marginale — cohérent avec sa corrélation plus faible observée en Figure 4.6.

Comparaison avec la littérature

Les performances obtenues ($R^2 = 0,751$ pour le meilleur modèle) sont sensiblement inférieures à celles rapportées par Sharma et al. [6] sur le jeu de données Ames Housing ($R^2 \approx 0,89$). Cet écart s’explique principalement par deux facteurs : le volume de données (603 contre plusieurs milliers d’observations pour Ames Housing) et surtout la richesse des variables descriptives (4 variables mobilisées ici, contre 79 pour Ames Housing, incluant l’âge du bien, la qualité des matériaux, l’état de la toiture, etc., absentes des annonces Expat-Dakar). Le classement relatif des modèles — méthodes ensemblistes surpassant nettement la régression linéaire — est en revanche cohérent avec Truong et al. [7] et




FIGURE 4.4 – Prix en fonction de la surface, par type de bien

Nwankwo et al. [3].

Le fait que le MLP n'égale pas Random Forest est également cohérent avec les observations de Yazdani [8] : sur un volume de données de l'ordre de quelques centaines d'observations, les réseaux de neurones ne disposent généralement pas d'assez d'exemples pour exprimer leur capacité de modélisation, contrairement aux méthodes ensemblistes à base d'arbres, plus robustes dans ce régime de données.

Discussion

Plusieurs limites doivent être soulignées. **Premièrement**, la richesse des caractéristiques disponibles est restreinte aux champs affichés systématiquement par Expat-Dakar (surface, chambres, quartier, type) ; des variables reconnues comme déterminantes dans la littérature — âge du bien, état/qualité de construction, proximité des axes routiers ou équipements, statut foncier (titre foncier ou non, un facteur pourtant mentionné dans plusieurs titres d'annonces observées lors de la collecte) — n'ont pas pu être exploitées de façon structurée. **Deuxièmement**, la concentration géographique du jeu de données (85 % des annonces à Dakar) limite la capacité du modèle à généraliser sur le reste du territoire. **Troisièmement**, les prix collectés sont des prix affichés, négociables par nature, et non des prix de transaction effectivement conclus, ce qui introduit un bruit structurel difficilement réductible sans accès à des données notariales.




FIGURE 4.5 – Prix en fonction du nombre de chambres




FIGURE 4.6 – Corrélations entre variables numériques

4.2 II. Outils de développement et de déploiement

4.2.1 Environnement de développement

Le développement a été réalisé en Python, avec une phase d'exploration et de modélisation menée sous forme de notebooks Jupyter, conçus pour être exécutés indifféremment en local ou sur Google Colab (chargement des données avec repli automatique sur un import manuel si le fichier n'est pas présent dans la session). L'éditeur Visual Studio Code a été utilisé pour le développement du script de collecte et de l'application finale.



FIGURE 4.7 – Comparaison visuelle des modèles (RMSE, MAPE, R^2)

FIGURE 4.8 – Importance des variables — Random Forest et XGBoost

4.2.2 Technologies de développement

- **Collecte de données** : requests et BeautifulSoup (analyse et extraction HTML).
- **Traitement de données** : pandas, numpy.
- **Modélisation** : scikit-learn [4] (régression linéaire, Random Forest, MLP, pipelines de prétraitement, recherche d'hyperparamètres), xgboost [2].
- **Visualisation** : matplotlib, seaborn (notebooks), plotly (interface interactive).
- **Interface graphique** : Streamlit.
- **Persistance des modèles** : joblib.

4.2.3 Architecture de la solution

Le pipeline du projet est organisé en quatre étapes séquentielles et indépendantes, matérialisées par autant de composants :

1. `src/scrapper.py` — collecte les annonces et produit `data/raw/expat_dakar_listings_raw.csv`.
2. `notebooks/01_eda_nettoyage.ipynb` — nettoie les données et produit

`data/processed/expat_dakar_listings_clean.csv`, accompagné des visualisations exploratoires.

3. `notebooks/02_modelisation.ipynb` — encode les variables, entraîne et optimise les quatre modèles, puis sauvegarde les pipelines entraînés (`models/*.joblib`) ainsi qu'un fichier de métadonnées (`models/metadata.json`) décrivant les catégories disponibles, les plages de valeurs et les performances de chaque modèle.
4. `app.py` — application Streamlit consommant les modèles et métadonnées sauvegardés pour proposer prédiction, exploration des données et comparaison des modèles.

Chaque modèle est encapsulé dans un *pipeline* scikit-learn intégrant le prétraitement (mise à l'échelle des variables numériques, encodage *one-hot* des variables catégorielles) et l'estimateur, garantissant que les mêmes transformations sont appliquées de façon identique à l'entraînement et à l'inférence dans l'application finale.

4.2.4 Architecture et services du déploiement

L'application est exécutable localement (`streamlit run app.py`) et a été conçue pour être déployable sans modification sur *Streamlit Community Cloud*, à l'image du projet de référence pris comme modèle pour ce document. Un fichier `requirements.txt` liste les dépendances nécessaires à la reproduction de l'environnement d'exécution.

4.3 Conclusion

L'implémentation réalisée démontre la faisabilité d'un système d'estimation immobilière pour le marché sénégalais à partir de données librement accessibles en ligne. Le modèle Random Forest optimisé constitue la meilleure solution identifiée, avec des performances certes inférieures à celles obtenues sur des jeux de données occidentaux plus riches, mais cohérentes avec l'état de l'art compte tenu des contraintes de données propres au contexte sénégalais. L'architecture modulaire retenue — collecte, nettoyage, modélisation, restitution — sépare clairement les responsabilités et facilite l'évolution future de chaque composant, discutée en conclusion générale.

Chapitre 5

Conclusion générale

5.1 Bilan de l'étude

Ce projet informatique avait pour objectif de développer un système d'estimation de la valeur des biens immobiliers résidentiels au Sénégal, en explorant l'apport de l'optimisation des hyperparamètres d'entraînement et en rendant les résultats accessibles via une interface graphique interactive. Les trois objectifs fixés en introduction ont été atteints :

- un jeu de données de 603 annonces exploitables a été constitué par extraction automatisée depuis Expat-Dakar, en l'absence de toute source structurée préexistante pour le marché sénégalais ;
- quatre modèles ont été entraînés et comparés selon un protocole homogène, avec optimisation systématique des hyperparamètres par recherche aléatoire et validation croisée pour les trois modèles les plus complexes ; le modèle Random Forest optimisé obtient les meilleures performances (MAE de 73,3 millions FCFA, MAPE de 34,0 %, R^2 de 0,751), devançant XGBoost et le réseau de neurones MLP ;
- une application Streamlit interactive permet d'estimer le prix d'un bien, de comparer les prédictions des quatre modèles, et d'explorer visuellement le jeu de données et les performances des modèles.

Le projet confirme, dans le contexte spécifique et peu documenté du marché immobilier sénégalais, des tendances déjà observées dans la littérature internationale : la supériorité des méthodes ensemblistes à base d'arbres sur la régression linéaire classique, et la nécessité d'un volume de données conséquent pour que les réseaux de neurones expriment un avantage sur ces méthodes.

5.2 Perspectives

Plusieurs axes d'amélioration se dégagent de ce travail :

1. **Enrichissement des données.** L'intégration de sources complémentaires (autres plateformes d'annonces, données notariales si elles venaient à être ouvertes) permettrait d'augmenter le volume et la diversité géographique du jeu de données, actuellement très concentré sur Dakar.

2. **Enrichissement des variables.** L'ajout de caractéristiques non disponibles dans les annonces actuelles — âge du bien, statut foncier (titre foncier), proximité d'axes ou d'équipements, à obtenir par géocodage des adresses — permettrait de rapprocher les performances du modèle de celles obtenues sur des jeux de données occidentaux plus riches en variables.
3. **Suivi temporel des prix.** La collecte périodique des mêmes annonces permettrait de suivre l'évolution des prix dans le temps et d'enrichir le modèle d'une dimension temporelle, actuellement absente.
4. **Modèles d'ensemble combinés.** Une combinaison (*stacking*) des prédictions de Random Forest, XGBoost et du MLP pourrait améliorer encore la robustesse des estimations.
5. **Déploiement public.** La mise en ligne de l'application sur Streamlit Community Cloud rendrait l'outil accessible au grand public, à l'image du projet de référence ayant inspiré la structure de ce document.

En définitive, ce projet constitue une première contribution méthodologique à l'estimation automatisée des prix immobiliers au Sénégal, et pose les bases d'un outil dont la précision pourrait être significativement améliorée par un enrichissement futur des données mobilisées.

Bibliographie

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1) :5–32, 2001. doi : 10.1023/A:1010933404324.
- [2] Tianqi Chen and Carlos Guestrin. XGBoost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, San Francisco, CA, USA, 2016.
- [3] Mmesoma Peace Nwankwo, Ndukaku Macdonald Onyeizu, Emmanuel Chibuogu Asogwa, Chukwuogo Okwuchukwu Ejike, and Okechukwu J. Obulezi. Prediction of house prices in lagos-nigeria using machine learning models. *European Journal of Theoretical and Applied Sciences*, 1(5), 2023. doi : 10.59324/ejtas.2023.1(5).22.
- [4] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn : Machine learning in python. *Journal of Machine Learning Research*, 12 :2825–2830, 2011.
- [5] Sherwin Rosen. Hedonic prices and implicit markets : Product differentiation in pure competition. *Journal of Political Economy*, 82(1) :34–55, 1974.
- [6] Harshita Sharma, Hitesh Harsora, and Bayode Ogunleye. An optimal house price prediction algorithm : XGBoost. *Analytics*, 3(1) :30–45, 2024. doi : 10.3390/analytics3010003.
- [7] Quang Truong, Minh Nguyen, Hy Dang, and Bo Mei. Housing price prediction via improved machine learning techniques. *Procedia Computer Science*, 174 :433–442, 2020.
- [8] Mahdieh Yazdani. Machine learning, deep learning, and hedonic methods for real estate price prediction. arXiv :2110.07151, 2021.

Webographie

- Expat-Dakar — plateforme d’annonces, source des données immobilières collectées.
<https://www.expat-dakar.com/>
- Agence Nationale de la Statistique et de la Démographie du Sénégal (ANSD) — indices du coût de la construction et des prix des matériaux, contexte macro-économique du secteur.
<https://www.ansd.sn/>
- Observatoire des prix immobiliers au Sénégal.
<https://annonces-immobilieres-senegal.com/observatoire-prix-immobilier-senegal/>
- Documentation officielle scikit-learn.
<https://scikit-learn.org/>
- Documentation officielle XGBoost.
<https://xgboost.readthedocs.io/>
- Documentation officielle Streamlit.
<https://docs.streamlit.io/>

Annexe A

Annexes

A.1 Extrait du script de collecte (src/scrapper.py)

```
def parse_listing_card(anchor) -> dict:
    data = anchor.attrs

    bedrooms_tag = anchor.select_one(
        ".listing-card__header__tags__item--no-of-bedrooms")
    surface_tag = anchor.select_one(
        ".listing-card__header__tags__item--square-metres")
    bedrooms = extract_int_from_class(
        bedrooms_tag.get("class", []),
        "listing-card__header__tags__item--no-of-bedrooms_"
    ) if bedrooms_tag else None
    surface = extract_int_from_class(
        surface_tag.get("class", []),
        "listing-card__header__tags__item--square-metres_"
    ) if surface_tag else None

    return {
        "listing_id": data.get("data-t-listing_id"),
        "title": data.get("data-t-listing_title"),
        "category": data.get("data-t-listing_category_title"),
        "price_fcfa": data.get("data-t-listing_price"),
        "currency": data.get("data-t-listing_currency"),
        "bedrooms": bedrooms,
        "surface_m2": surface,
        "url": data.get("href"),
    }
```

Listing A.1 – Extraction structurée d’une annonce à partir de ses attributs HTML `data-t-listing_*`

A.2 Pipeline de prétraitement et d'entraînement (scikit-learn)

```
preprocessor = ColumnTransformer(
    transformers=[
        ("num", StandardScaler(), NUMERIC_FEATURES),
        ("cat", OneHotEncoder(handle_unknown="ignore"),
         CATEGORICAL_FEATURES),
    ]
)

rf_pipeline = Pipeline([
    ("preprocessor", preprocessor),
    ("model", RandomForestRegressor(random_state=RANDOM_STATE)),
])

rf_search = RandomizedSearchCV(
    rf_pipeline,
    param_distributions=rf_param_distributions,
    n_iter=30,
    cv=KFold(5, shuffle=True, random_state=RANDOM_STATE),
    scoring="neg_mean_absolute_error",
    random_state=RANDOM_STATE,
    n_jobs=-1,
)
```

Listing A.2 – Pipeline de prétraitement commun à tous les modèles

A.3 Liste des quartiers conservés individuellement

Les 33 quartiers suivants comptent chacun au moins 5 annonces dans le jeu de données nettoyé et sont conservés comme catégories individuelles (les quartiers moins représentés sont regroupés sous la catégorie **Autre**) : Almadies, Point-E, Mermoz, Mamelles, Fann, Ngor, Virage, Saly, Ngaparou, Sacré-Cœur, Amitié, Dakar, Plateau, Mbao, Nguering, VDN, Ouakam, Somone, Lac Rose, Yoff, et treize autres quartiers de moindre fréquence.

A.4 Structure du dépôt de code

```
MemoireM1/
src/scrapper.py Collecte des annonces
data/raw/ Donnees brutes scrapees
data/processed/ Donnees nettoyees
```



```
notebooks/  
  01_eda_nettoyage.ipynb Nettoyage + analyse exploratoire  
  02_modelisation.ipynb Modelisation + optimisation  
models/ Modeles entraines + metadonnees  
app.py Interface Streamlit  
requirements.txt Dependances  
rapport/ Present document (LaTeX)
```

Table des matières

Dédicace	i
Remerciements	ii
Glossaire	iii
Résumé	vi
Abstract	vii
Sommaire	viii
1 Introduction	1
1.1 Contexte et justification	1
1.2 Objectifs de la recherche	1
1.3 Structure du projet informatique	2
1.4 Conclusion	2
2 État de l’art	3
2.1 État de l’art sur le domaine d’application	3
2.2 État de l’art sur les travaux de recherche pertinents liés au sujet	3
2.3 Identification des zones de recherche manquantes liées au sujet	4
2.4 Conclusion	5
3 Analyse de besoins et méthodologie	6
3.1 I. Spécification des besoins et des données	6
3.1.1 Analyse et spécification des besoins	6
3.1.2 Sources de données	6
3.1.3 Processus de collecte	7
3.1.4 Pré-processing des données	7
3.2 II. Méthodologie	8
3.2.1 Choix des algorithmes et modèles	8
3.2.2 Justification des choix	8
3.2.3 Paramètres et configuration	9
3.2.4 Évaluation des performances	9
3.2.5 Métriques utilisées	9

3.2.6	Protocole d'évaluation	10
3.3	Conclusion	10
4	Implémentation	11
4.1	Résultats	11
4.1.1	Analyse exploratoire des données	11
4.1.2	Résultats des modèles	12
4.1.3	Interprétation des résultats	13
4.2	II. Outils de développement et de déploiement	15
4.2.1	Environnement de développement	15
4.2.2	Technologies de développement	16
4.2.3	Architecture de la solution	16
4.2.4	Architecture et services du déploiement	17
4.3	Conclusion	17
5	Conclusion générale	18
5.1	Bilan de l'étude	18
5.2	Perspectives	18
	Bibliographie	20
	Webographie	21
A	Annexes	22
A.1	Extrait du script de collecte (<code>src/scrapper.py</code>)	22
A.2	Pipeline de prétraitement et d'entraînement (<code>scikit-learn</code>)	23
A.3	Liste des quartiers conservés individuellement	23
A.4	Structure du dépôt de code	23